

AUTO-TUNE

后续研发路线与实施评估

研发执行版 · 按当前进度、业务使用量与阶段验收更新

项目	内容
文档用途	研发排期、批次拆分、验收与范围控制；不作为对外宣传或管理层汇报材料
当前稳定版本	Auto-Tune Studio v0.1
当前验证基线	160 passed, 2 条既有 sklearn PCA warning；已完成真实 1-epoch 调优验证
本次关键调整	业务优先采用 YOLOv8；Research 记录讨论形成的初步方案；Cloud 仅保留方向性评估
修订日期	2026-08-20

执行结论：先把 Studio 建设成可安装、可恢复、可维护的正式产品。Research 与 Cloud 均为后续独立软件：Research 按本轮讨论保留初步方案，正式开发前另行立项；Cloud 暂不进入编码和详细排期。

1. 本次修订结论

本文件替代此前偏汇报型的表达，直接服务后续研发实施。所有阶段都按“已完成、下一批、后续、暂缓”标注，不再把框架预留或下拉选项等同于正式支持。

- 1. Studio 继续作为唯一近期主产品，先完成可靠性、SQLite、多数据集、Linux、安装交付和高频任务闭环。
- 2. YOLO 版本按真实使用量收缩：YOLOv8 为主线；YOLOv5 仅维护老项目 Detect；YOLO11/YOLO26 暂不承诺。
- 3. Studio 当前任务范围固定为 YOLOv8 Detect、YOLOv8 Classify 和 YOLOv5 Detect；其他版本与任务不进入本阶段分析和产品完成标准。
- 4. Research 0.1 从 YOLO11 调整为 YOLOv8 Detect，以受控结构组合实现类似 autoresearch 的自主实验体验。
- 5. Research 首版不允许 LLM 修改 Python 源码；后期受限代码研究必须单独立项、单独安全评审。

1.1 产品优先顺序

顺序	产品	当前决定	启动条件
1	Auto-Tune Studio	持续建设，形成正式单机产品	立即按小批次推进
2	Auto-Tune Research	讨论方向：YOLOv8 Detect 受控结构研究	Studio 稳定后另行立项、规格确认与重新估算
3	Auto-Tune Cloud	仅保留方向性评估，不做实施排期	先完成业务、部署、租户、算力与 CVAT 需求调研

1.2 内容确定性分级

范围	本文件效力	使用方式
Studio	当前执行依据	可据此拆分小批次、形成规格并进入编码验收
Research	讨论稿/初步评估	记录已确认的方向，不等同于正式立项规格或交付承诺
Cloud	方向性/模糊评估	只说明产品边界和可能复杂度；后续确定方案后再补详细时间进度

1.3 三款软件的独立性

Studio、Research、Cloud 均可独立安装、运行和发布。三者不共享安装程序，也不直接复用 UI、进程管理或数据库实现；只共享版本化的数据和实验协议。Research 不能成为 Studio 的隐藏依赖，Cloud 也不能把 Studio 的本地 JSON 和 subprocess 直接包装成平台。

2. 当前基线与禁止回归边界

2.1 已完成并验收

- A0 审计闭环：LLM 原文、候选参数、护栏值、实际参数、精确命令、before/after/delta 和失败终态可追溯。
- 普通训练与自动调优统一收尾：共用 KPI、Module B 分析、统一历史、结构化错误和产物索引。
- 参考指标与参考参数绑定同一个 reference_run，指标来自对应 results.csv 最终轮。
- 审计持久化失败、决策失败、护栏拒绝和训练预检失败均为 fatal，不得启动训练。
- 历史页已展示四项 KPI、epoch、参数、来源、分析状态、AI 诊断、安全护栏和审计入口。

2.2 后续不得破坏

兼容边界：缺失指标与真实 0 必须区分；训练成功但分析失败属于部分成功；审计失败仍为 fatal；旧 JSON 记录必须保持可读；目录选择是正式数据入口，ZIP 只保留遗留兼容。

3. Studio 实施路线（当前主线）

Studio 的目标不是继续堆叠模型名称，而是形成操作人员可以安装、配置、训练、恢复、比较和导出的稳定产品。以下顺序优先于 Research 与 Cloud 编码。

3.1 S1 可靠性与安全收尾（下一阶段）

批次	状态	要做事项	验收重点	人日
S1.1	下一批候选	训练日志分层：默认显示 epoch 关键指标，完整日志折叠	长训练不淹没页面；错误栈可查询；SSE 不回归	2-4
S1.2	待实施	不可变数据快照，不移动原始文件	原目录不变；划分可校验；运行可复现	3-6
S1.3	待实施	API Key 迁移、配置脱敏与轮换说明	配置、日志、审计和导出不泄漏	2-4

批次	状态	要做事项	验收重点	人日
S1.4	待实施	目录成员数、总容量、ZIP 解压容量与路径安全	处理前拒绝超限；链接逃逸和越权路径被拦截	3-6
S1.5	后续	运行身份、PID、阶段和最后事件持久化	刷新/重连能说明真实状态，不伪造恢复	3-6

3.2 S2 SQLite 与多数据集

SQLite 只作为 Studio 本地单用户索引库，不承担登录、角色、JWT 或多租户。A0 审计继续保留为可移植 JSON 事实文件。

- 数据集索引：名称、目录引用、任务类型、快照身份、校验状态、最近使用时间。
- 实验索引：训练、调优、报告、权重、配置和产物位置。
- 历史能力：筛选、标签、归档、运行对比和报告导出。
- 迁移要求：旧 experiment_history.json 幂等迁移；损坏 JSON 只读保护；迁移失败不覆盖事实文件。

估算：6-12 人日。涉及 Schema 迁移、损坏保护、历史对比和 UI，不应与 S1 同批编码。

3.3 S2.5 YOLO 版本与任务闭环

本阶段必须在 S3 安装交付之前完成。当前只分析并产品化验收三项任务：YOLOv8 Detect、YOLOv8 Classify 和 YOLOv5 Detect。三项通过后，即认定 Studio 当前版本的“可支持任务”范围完成；Segment、OBB、YOLO11 和 YOLO26 不计入当前产品完成标准。

任务	要做事项	完成条件	初步人日
YOLOv8 Detect	回归现有训练、调优、审计、分析、历史和导出闭环	最小真实数据短 epoch 及失败路径、UI 和产物验收通过	2-4
YOLOv8 Classify	确认 Ultralytics 分类数据组织、训练参数、指标、结果解析和 UI 差异	目录接入、训练、Top-1/Top-5、历史、报告和错误处理通过	6-10
YOLOv5 Detect	固化老项目兼容边界、独立命令、旧指标映射和产物识别	真实旧项目样本短 epoch、历史和报告可读，且不影响 YOLOv8	2-4

估算：初步约 10-18 人日。YOLOv8 Classify 是主要不确定项，应先确认真实业务数据组织和 Ultralytics 分类链路，再锁定详细工期。完成本阶段后不再为 Studio 当前版本追加其他 YOLO 版本或任务。

3.4 S3 Linux、安装、升级与卸载

Linux 服务器通常不提供桌面环境，Studio 仍以 Web 方式运行：管理员通过 SSH 部署和维护，操作人员在其他电脑的浏览器中访问。Linux 交付采用双轨方案——Docker Compose 作为服务器首选，原生安装作为受限环境、调试和高级用户的兼容方案；两者使用同一配置、数据目录和 SQLite Schema。

范围	要做事项	验收
S3.1 Linux 基础兼容	先限定 Ubuntu Server LTS；适配路径、权限、大小写、编码、符号链接、进程和 GPU 检测	无桌面环境完成 pytest、目录接入和短 epoch 训练
S3.2 Docker 首选交付	提供 CPU/GPU 镜像及 Docker Compose；持久化配置、SQLite、数据、权重、日志和报告；增加健康检查	通过 SSH 部署，远程浏览器可用；容器重建或升级不丢数据
S3.3 Linux 原生安装	保留 Python 虚拟环境安装，提供 systemd 服务、启动停止脚本和联网/离线依赖说明	Docker 受限环境可安装；重启自动恢复服务且不遗留孤儿训练进程
Windows 安装	保留本地原生安装与首次向导；检测 CUDA、GPU、磁盘和端口	非开发人员按文档完成安装与首次训练
升级迁移	配置、SQLite、JSON Schema 与历史升级	升级失败可回退，旧记录可读
卸载	程序与用户数据分离；容器/原生卸载采用相同保留策略	默认只移除程序或容器，不删除数据集、权重、数据库、报告和历史；彻底清理需单独确认

实施边界：Docker Compose 是 Linux 服务器正式推荐方案，但 Docker 化不等于 Cloud 平台。S3 只解决单实例稳定部署；多用户、任务队列、GPU 调度、权限、配额、对象存储和 CVAT 协作仍属于后续 Cloud。

估算：完整交付初步约 10–20 人日，其中先完成 Linux 基础兼容和 Docker 交付，再补齐原生安装生命周期；首次 Linux 产品化经验不足应预留环境验证和文档试装时间。

4. YOLO 版本与任务范围裁剪

本节是 3.3 阶段的范围依据与验收边界，不是排在 S3 之后的新增研发阶段。版本和任务选择以团队真实使用量为依据；当前产品只交付 YOLOv8 Detect、YOLOv8 Classify 和 YOLOv5 Detect 三项，其余内容均不计入 Studio 当前版本完成标准。

4.1 当前业务判断

维度	团队现状	研发结论
YOLOv8 Detect	当前使用最多	Studio 核心任务，完成全部产品闭环
YOLOv8 Classify	任务使用频率第二	Studio 分类任务唯一实现范围
YOLOv5 Detect	老项目仍在使用的	只维护 Detect 遗留兼容，不进入 Research
其他版本/任务	当前产品价值不足或使用量较少	不分析、不适配，不计入当前 Studio 完成标准

4.2 正式产品矩阵

版本/任务	Studio	Research	支持等级	备注
YOLOv8 Detect	完整闭环	Research 0.1	核心/P0	训练、调优、审计、报告、安装均需验收
YOLOv8 Classify	完整分类闭环	不在 Research 0.1	核心/P1	训练、Top-1/Top-5、历史、报告、失败路径和 UI 均需验收
YOLOv5 Detect	遗留适配器	不支持	维护/P1	独立命令与旧指标映射，不扩展结构研究
其他版本/任务	不支持	不纳入	范围外	后续只有形成新的业务决策和独立规格才重新进入路线

4.3 支持声明规则

只有完成最小合法数据集、短 epoch 训练、结果解析、Module B 报告、统一历史、失败路径和 UI 测试后，才能宣称某个版本/任务“正式支持”。仅出现模型名称、配置字段或成功构造命令，只能称为框架预留。

4.4 分类任务固定边界

当前决定：Studio 当前分类任务固定为 YOLOv8 Classify，不在本阶段设计 ResNet、MobileNet 或通用分类适配层。若未来业务框架发生变化，应另行立项，不扩张本批次。

5. Auto-Tune Research 0.1 实施设计

以下为本轮讨论形成的 Research 0.1 初步设计，用于保存方向和辅助后续立项，不是最终实施规格。Research 拟作为独立安装的软件，参考 karpathy/autoresearch 的实验循环，但只借鉴“固定事实层、固定预算、提出方案、运行、比较、保留或放弃”的方法，不复制其直接修改训练源码和无限循环的默认边界。

5.1 已确认范围

项目	Research 0.1 决定
研究对象	YOLOv8 Detect
结构方式	注册模块 + 固定插槽
LLM 权限	只提交结构化 ExperimentSpec，不得提交 Python 代码或系统命令
实验体验	自主提出假设、执行实验、读取证据、keep/discard/review 并继续
运行模式	有限批次模式 + 用户明确开启的持续研究模式
Head 范围	首版固定检测 Head，优先研究 Backbone、Neck、Attention 与有限深宽参数
源码修改	首版禁止；后续受限代码研究单独立项

5.2 autoresearch 映射

autoresearch 机制	Research 0.1 映射	安全调整
prepare.py 不可修改	数据快照、训练预算、评价器与事实解析不可修改	事实层只读并记录校验摘要
Agent 修改 train.py	Agent 提交受控结构规格	只能选择注册模块和允许插槽
固定 5 分钟	固定 epoch、时间或 GPU 预算	超时、显存和磁盘均设硬限制
val_bpb 唯一指标	主指标 + 资源与复杂度约束	不能只用 mAP 决定 keep
keep/discard/crash	keep/discard/crash/invalid/review	低置信度与权衡冲突进入 review
results.tsv	SQLite 实验账本 + JSON 事实记录 + 可导出报告	状态原子化，损坏不覆盖
无限循环	有限批次默认；持续模式显式开启	支持熔断、安全停止和恢复

5.3 总体架构

Research Policy: 研究目标、主指标、允许模块、预算、停止条件和保留规则。

结构事实层: 解析 YOLOv8 Detect 拓扑、通道、参数量、FLOPs 和允许插槽；不可被 Agent 修改。

受控结构生成器: 将通过 Schema 和白名单的候选生成临时 YOLO 结构配置。

实验执行器: 建立独立实验目录，依次执行静态检查、模型实例化、短前向、训练和资源监控。

评价与决策器: 依据确定性指标与 Policy 输出 keep/discard/review/crash/invalid。

实验账本与 UI: 展示当前基线、实验队列、结构谱系、差异、指标、资源和最终总结。

5.4 自主实验数据流

- 1. 读取 Research Policy、当前基线和历史实验。
- 2. LLM 提出结构假设并提交结构化 ExperimentSpec。
- 3. 执行 Schema、模块白名单、插槽兼容和资源上限校验。
- 4. 生成候选结构，完成模型实例化与最小前向探测。
- 5. 按固定预算训练，收集指标、显存、时长、参数量、FLOPs 和推理速度。
- 6. 确定性决策器输出实验状态；LLM 只能解释事实并提出下一轮。
- 7. keep 时更新当前基线；discard/review/crash/invalid 不覆盖基线。
- 8. 达到预算、连续失败或用户停止条件后生成研究总结。

6. Research 结构组合与评价规则

6.1 首版允许动作

- 替换登记过的 Backbone 特征提取模块。
- 在指定 Backbone 末端插入登记过的 Attention 模块。
- 替换登记过的 Neck 特征融合模块。
- 在白名单范围内调整指定层重复次数、深度倍率与宽度倍率。
- 替换 SPPF 等明确登记且接口兼容的模块。
- 为结构实验搭配少量白名单训练参数，但不得绕过 Studio 已有 Guardrails 思想。

6.2 首版禁止动作

- 修改 Python 源码、评价函数、数据划分和结果解析器。
- 安装依赖、执行任意命令或访问未授权目录。
- 自由重组检测 Head 或改变输出语义。
- 绕过模型实例化与短前向探测直接进入训练。
- 用 LLM 生成的文字覆盖真实训练指标或资源数据。
- 在未满足硬约束时由 LLM 强制判定为 keep。

6.3 评价与状态

状态	确定条件	后续行为
keep	主指标达到阈值，且显存、时长、复杂度等硬约束全部通过	候选成为下一轮基线
discard	收益不足或资源代价不满足 Policy	保留记录和产物索引，不改变基线

状态	确定条件	后续行为
review	精度与资源存在权衡、差异接近噪声或规则无法自动裁决	等待人工确认，不自动推进
crash	训练 OOM、超时、运行异常	记录错误、回收资源；连续失败可熔断
invalid	Schema、模块接口、拓扑或前向检查失败	不启动正式训练

6.4 指标口径

Research 不能只看单一 mAP。主指标由 Policy 指定，例如 mAP50-95；同时记录 Precision、Recall、参数量、FLOPs、峰值显存、训练时长、推理速度和结构复杂度。跨设备结果必须记录硬件与软件环境，不直接比较绝对时长。

6.5 两种运行模式

模式	默认行为	停止条件	适用场景
有限批次	默认启用	实验次数、总时长、GPU 预算、连续失败任一达到	日常可控研究与回归
持续研究	用户明确开启	人工停止、硬资源上限、连续失败熔断	夜间或长时间自主实验

7. Research 分阶段实施与工期

阶段	要做事项	验收门	人日
R0 研究协议	Policy、预算、停止条件、TrialRecord、环境与数据快照	评价事实不可修改；实验可复现	4-7
R1 结构事实	YOLOv8 Detect 解析、拓扑、参数量、FLOPs、插槽识别	解析结果与实际模型一致	5-8
R2 受控生成	模块注册、固定插槽、候选结构、静态与前向校验	非法组合训练启动数为 0	6-10
R3 自主闭环	LLM 假设、实验执行、状态决策、谱系、两种模式与报告	完成 20-30 轮仍保持基线和账本一致	7-11

Research 0.1 初步粗估：当前讨论口径约 22-36 人日，仅用于判断量级，不是排期或交付承诺。正式立项时需结合模块清单、数据、GPU 环境、UI 范围和验收轮数重新估算。

7.1 后续任务扩展

扩展	前置条件	新增范围	追加人日
Classify	Studio 分类框架与真实数据确认	分类结构、Top-1/Top-5、分类 Head 和数据协议	8-14
Segment	出现稳定业务需求	Mask 分支、分割指标、产物和结构插槽	7-12
OBB	明确项目与验收数据	旋转框 Head、角度、指标和推理产物	6-10
受限代码研究	R0.1 稳定且单独安全评审	隔离工作区、源码修改、依赖限制、回滚和沙箱	15-30

7.2 全任务成本判断

如果未来保持同等自主研究功能并覆盖 Detect、Classify、Segment、OBB，按当前讨论只能粗略判断为中大型研发工作，原始量级估算约 49-82 人日；若 Studio 先提供稳定的任务适配、数据快照和指标解析，可能缩减到约 40-65 人日。该数字不进入正式排期，任务范围确定后必须重新估算。

8. 批次执行与验收流程

继续执行当前已经验证的协作方式，每次只展开一个小批次。

1. Codex 读取交接记录、路线和实际代码，形成当前批次规格、失败策略与测试清单。
2. 艾卡审核范围，明确哪些内容本批实现、哪些内容后置。
3. Claude Code 仅实现业务代码和对应测试，并提交交付报告；不修改项目路线、README 和本执行文档。
4. Codex 独立审查代码，运行相关自动化测试；涉及 UI 时执行真实浏览器检查；涉及训练链路时使用最小数据和短 epoch。
5. 发现问题形成文本清单，修复后重新验收；只有明确验收通过才允许发布 GitHub 版本。
6. 发布前检查.gitignore、敏感信息、大文件、本机路径和待提交文件。

8.1 Research 每批最低测试

- 单元测试：Schema、模块注册、插槽兼容、资源上限、状态机和原子持久化。
- 负向契约：非法模块、未知字段、越界参数、前向失败、OOM、超时和账本写入失败。
- 集成测试：基线→候选→训练→评价→keep/discard→下一轮。
- 真实短训练：最小 YOLOv8 Detect 数据集，至少验证一个有效候选和一个被拒绝候选。
- UI 验证：有限/持续模式、停止、恢复、结构差异、指标零值/缺失值和报告导出。

9. 推荐的近期实施顺序

顺序	批次	输出	进入下一步条件
1	Studio S1.1 日志分层	默认关键指标 + 完整日志折叠	训练与错误 SSE 回归通过
2	Studio S1.2 数据快照	不可变 DatasetSnapshot	原始目录不变、训练可复现
3	Studio S1.3/S1.4 安全	密钥迁移、容量与路径限制	公开仓库和运行记录无凭据泄漏
4	Studio S2 SQLite	多数据集与实验索引	旧 JSON 迁移与损坏保护通过
5	Studio S2.5 三任务闭环	YOLOv8 Detect、YOLOv8 Classify、YOLOv5 Detect 产品化验收	三项短训练、指标、历史、报告、失败路径和 UI 全部通过
6	Studio S3 安装/Linux	Ubuntu Server 兼容、Docker Compose 首选交付、原生安装/systemd 兼容	非开发人员完成 Docker 部署；原生安装完成短训练
7	Research 立项评审	确认 R0/R1 规格、模块清单、数据、GPU 和验收预算	艾卡批准独立规格与重新估算
8	Research 后续批次	按批准后的 R0-R3 计划分批实施	不直接使用本讨论稿进入编码

10. 暂缓与触发条件

事项	当前决定	重新启动条件
YOLO11	暂缓正式适配和 Research	团队开始采用，且有真实数据、权重和验收项目
YOLO26	移出近期计划	生态成熟并出现明确业务迁移需求
Segment 通用支持	按需	出现稳定项目量，能提供回归数据
OBB 通用支持	项目级	现有 1-2 个项目确认需要产品化复用
Research 修改源码	Research 0.1 禁止	受控组合稳定、沙箱设计通过安全评审
Cloud	仅保留模糊评估，暂停编码和详细时间表	先确定客户、部署形态、多用户、远程 GPU、CVAT 协同及运维责任，再形成 C0 方案和排期

11. 风险清单

风险	影响	控制措施
版本与任务组合膨胀	回归矩阵失控，投入与业务价值不匹配	采用核心/遗留/按需/观察四级矩阵
Research 只追求精度	模型更慢、更大但被错误保留	主指标 + 显存/FLOPs/速度/时长硬约束
结构组合无效	大量训练前崩溃，浪费 GPU	Schema、拓扑、接口、实例化和短前向五层校验
预训练权重失配	实验比较不公平	记录加载比例、初始化策略并触发 review

风险	影响	控制措施
持续模式失控	资源耗尽、磁盘填满、重复实验	总预算、磁盘阈值、超时、连续失败熔断和重复检测
LLM 覆盖事实	结果不可复现	评价器与账本只接受确定性执行结果
Studio 与 Research 耦合	一个产品升级破坏另一个	独立仓库/安装，只共享版本化协议

12. 阶段完成定义

12.1 Studio 形成基础产品

- YOLOv8 Detect、YOLOv8 Classify 和 YOLOv5 Detect 三项均完成真实数据短训练、指标、历史、报告、失败路径和 UI 验收；这三项即为 Studio 当前版本全部可支持任务。
- 数据快照、SQLite、多数据集、历史对比和恢复信息可靠。
- Windows 保留原生安装；Linux Server 以 Docker Compose 为首选并保留原生安装/systemd 兼容，具备联网与离线安装、升级、卸载和故障排查文档。
- API 密钥、目录、容量、日志和导出满足公开发布安全要求。

12.2 Research 0.1 完成

- YOLOv8 Detect 结构事实层可复现，并能识别固定插槽。
- LLM 只能产生符合 Schema 的受控结构候选，非法组合不进入训练。
- 有限批次和持续研究均可安全停止、恢复和熔断。
- 至少完成 20–30 轮自动实验，keep/discard/review/crash/invalid 状态真实一致。
- 研究报告包含假设、结构差异、父子谱系、指标、资源、结论和可复现信息。

13. 参考与边界说明

Research 0.1 参考 karpathy/autoresearch 的轻量自主实验循环：固定事实层、固定预算、Agent 提出修改、运行实验、读取指标、保留或放弃。Auto-Tune Research 只借鉴方法，不直接把其单文件源码修改、Git reset 或无限循环原样搬入产品。

- karpathy/autoresearch：自主实验循环、固定预算、keep/discard/crash 与可修改范围。
- Auto-Tune Studio v0.1：提供已验收的审计、训练收尾、指标和失败策略参考。
- docs/development_handoff_20260814.md：当前稳定版本与禁止回归边界。
- docs/roadmap_20260814.md：三产品生态边界；后续需按本执行版业务裁剪同步更新。
- docs/implementation_plan_20260814.md：旧批次明细；执行前需按本文件重新拆分当前批次。

文档维护规则：完成每个批次后只回写实际完成状态、测试证据、偏差和遗留风险；未经真实训练和完整验收，不把“框架可用”改写为“正式支持”。

扩展软件说明：Research 和 Cloud 当前内容均可能随业务、数据、模型版本和部署方案变化。Research 保留本轮讨论结论作为立项输入；Cloud 只做模糊评估，待实施方案确定后再补充架构、批次、人员和详细时间进度。